Classificação

Queremos prever ou descrever a classe de um evento

Normalmente a classe em uma relação esta representada em um atributo especial, posicionado como último atributo da relação

Exemplos de Classificação

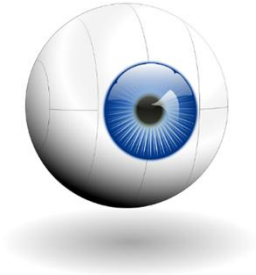

Modelo

Palavra	Spam	Não Spam
oferta	0,9	0,1
ganhe	0,8	0,2
preço	0,3	0,7
grátis	0,7	0,3

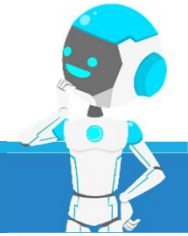

Medir o Desempenho do Modelo

Treino: Algoritmo processa dados e cria modelo

Validação: Dados são usados para ajustar o modelo

Teste: Dados são usados para avaliar a performance do modelo

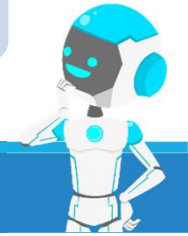

Hold-Out

Divide os dados em treino e teste

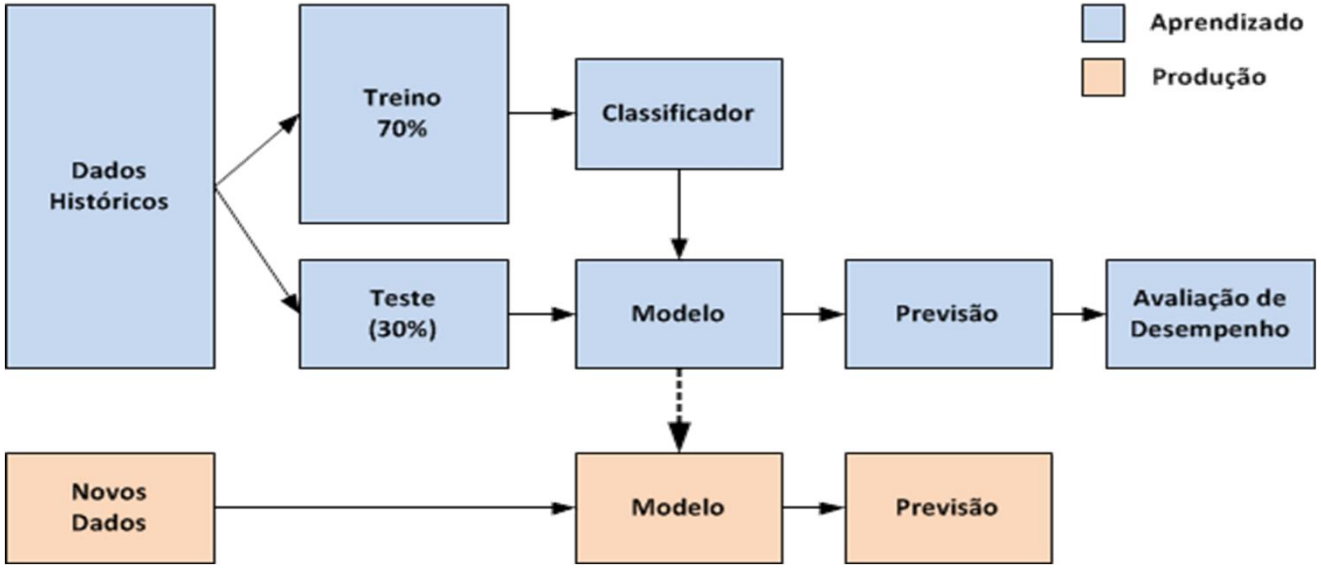

Validação Cruzada

Divide os dados em vários conjuntos menores

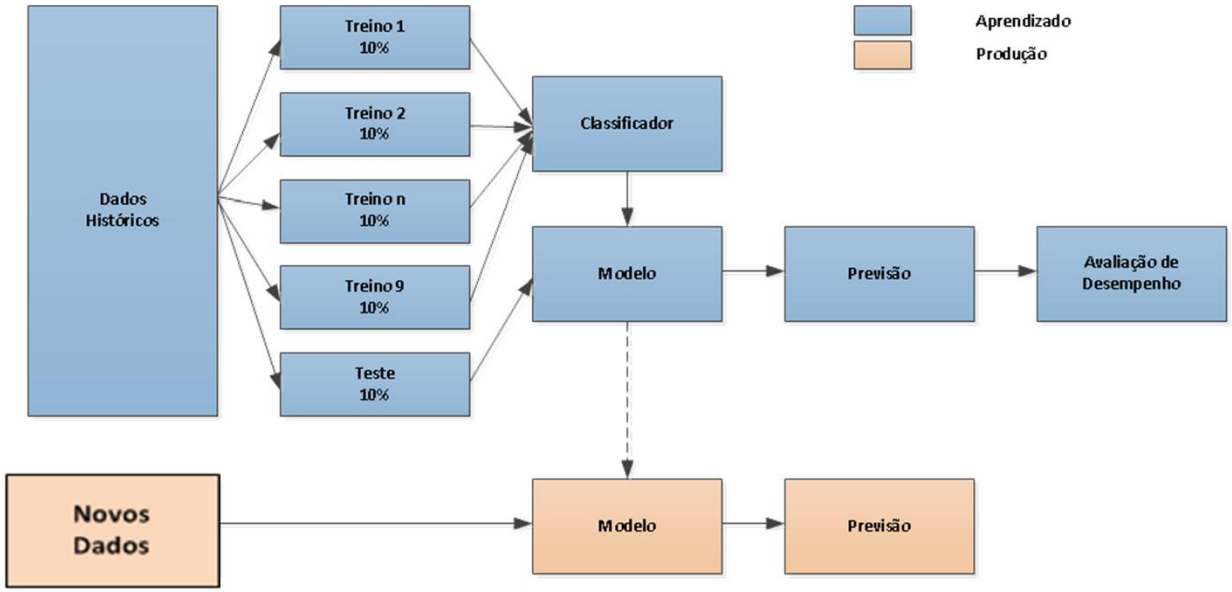

Leave-One-Out

Tipo de validação cruzada, que treina com todos os conjuntos de dados menos um

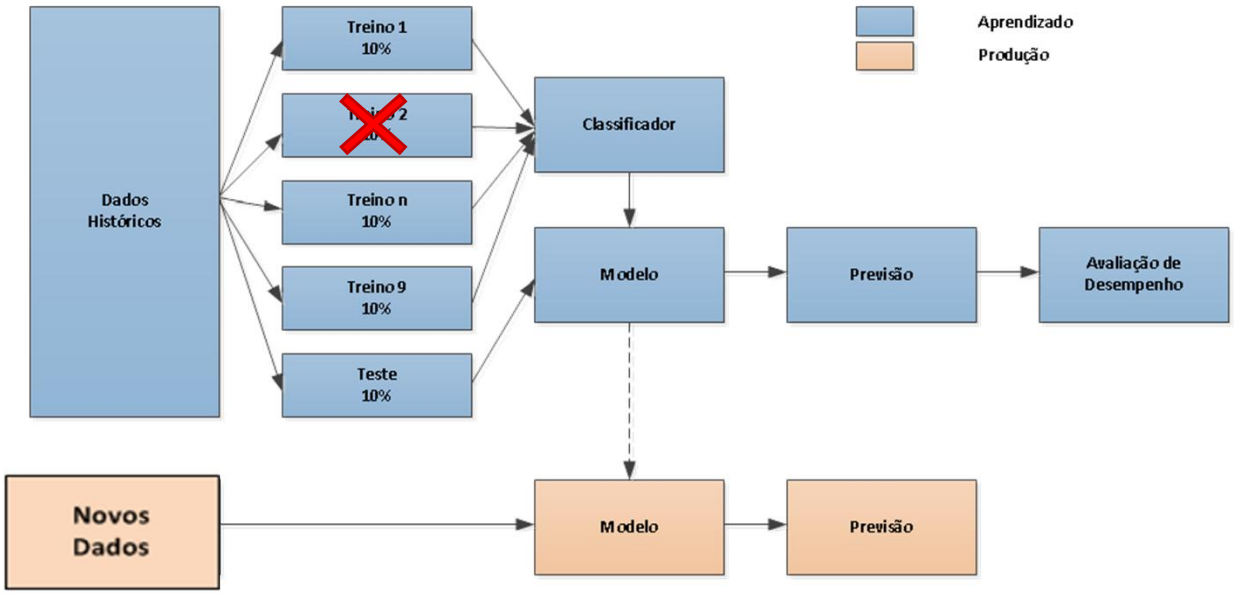

K-Fold

Tipo de validação Cruzada: Divide o conjunto de dados em k subconjuntos, treinar o modelo em k-1 subconjuntos e avaliá-lo no subconjunto restante. Esse processo é repetido k vezes,

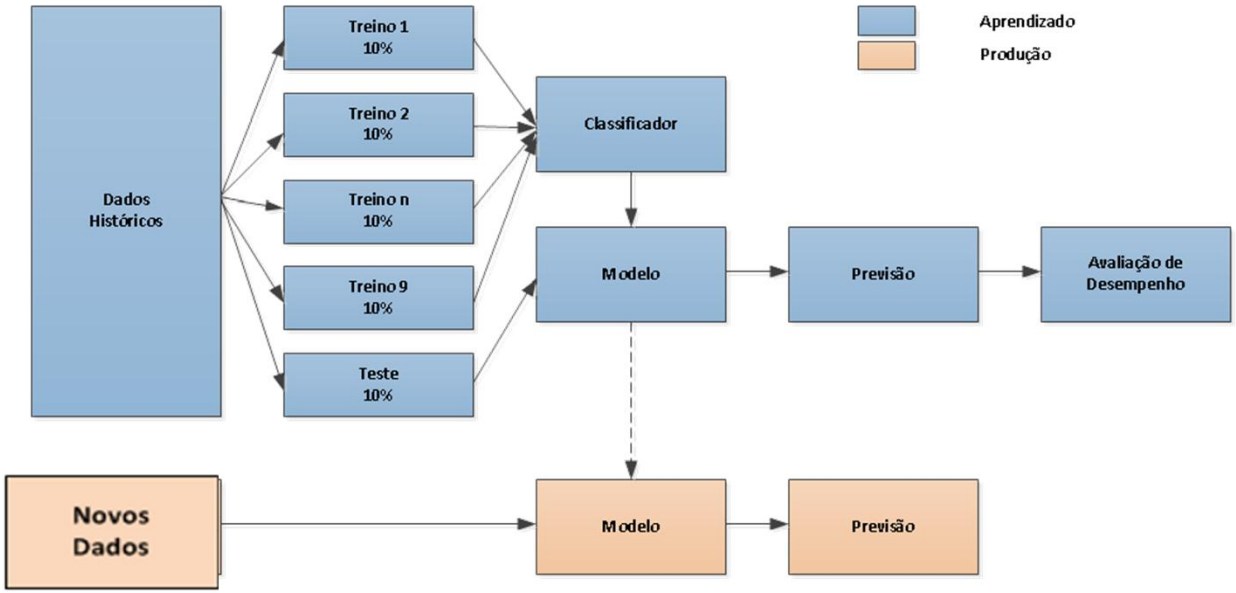

Subamostragem

É uma técnica que envolve a seleção de uma amostra aleatória de exemplos do conjunto de dados original para treinamento do modelo

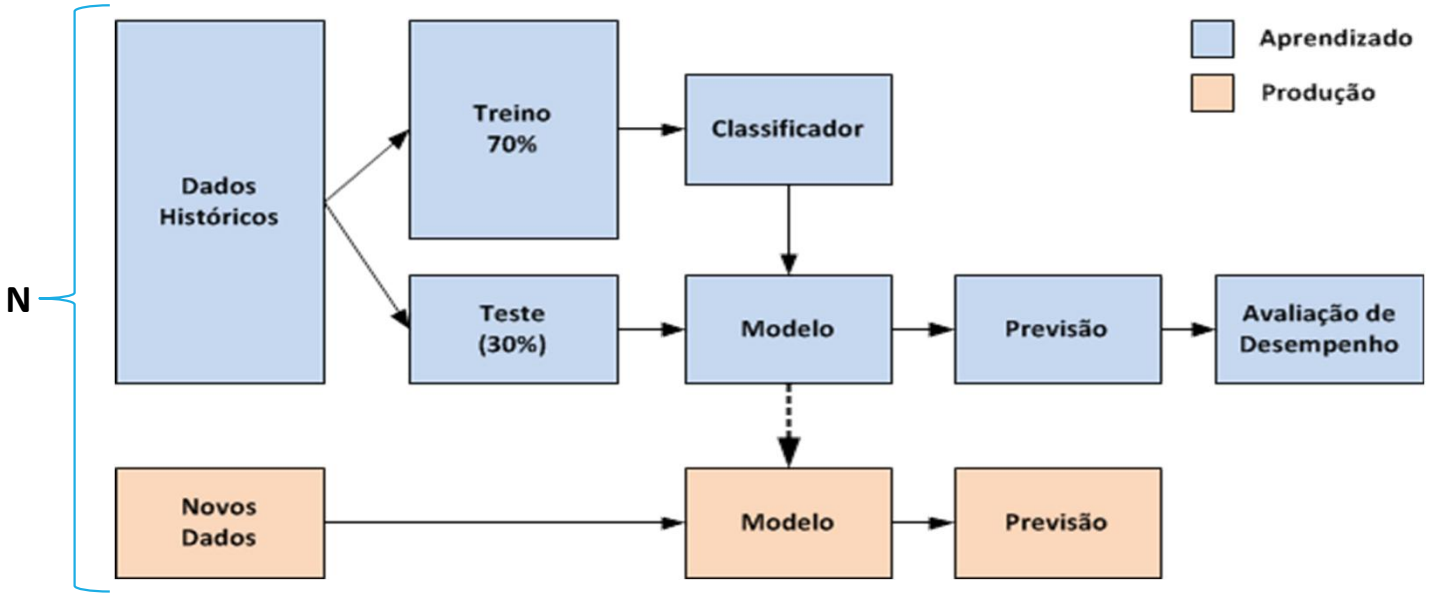

Generalização Versus Super Ajuste Versus Sub Ajuste

- O objetivo de todo classificador é criar modelos genéricos

Genérico Ajustado

Super/Sub

Super Ajuste

O modelo super ajustado funciona bem com dados de treino, mas tem o desempenho pobre em dados de teste ou de produção.

Super Ajuste

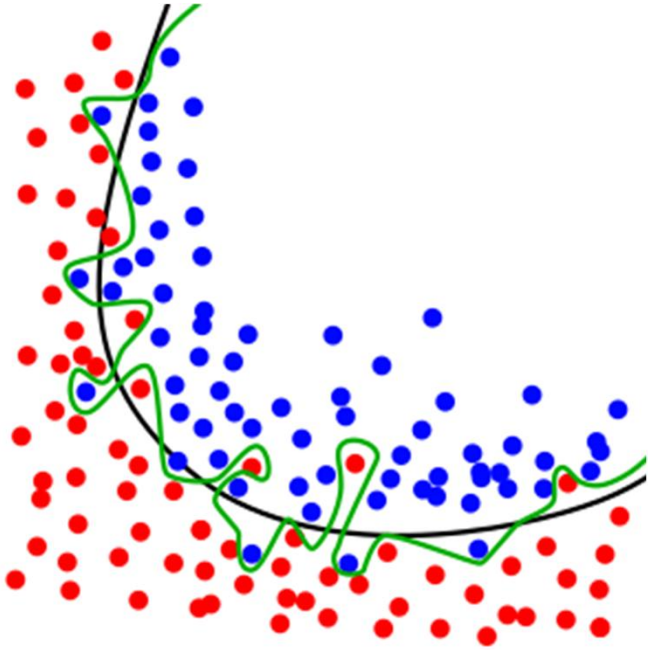

Causas de Super Ajuste

- Tamanho insuficiente do conjunto de dados
- Complexidade excessiva do modelo de treinamento
- Ruído nos dados de treinamento
- Seleção inadequada de atributos
- Falta de validação cruzada

Sub Ajuste

Modelo de machine learning não consegue se ajustar bem aos dados de treinamento e, portanto, também não consegue generalizar bem para novos dados.

Sub Ajuste

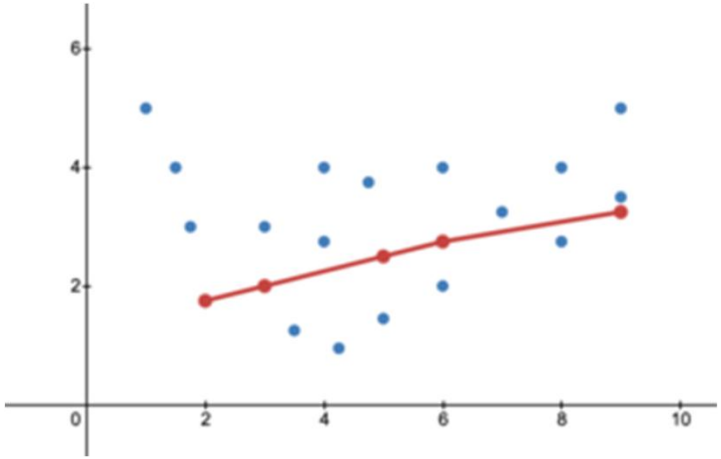

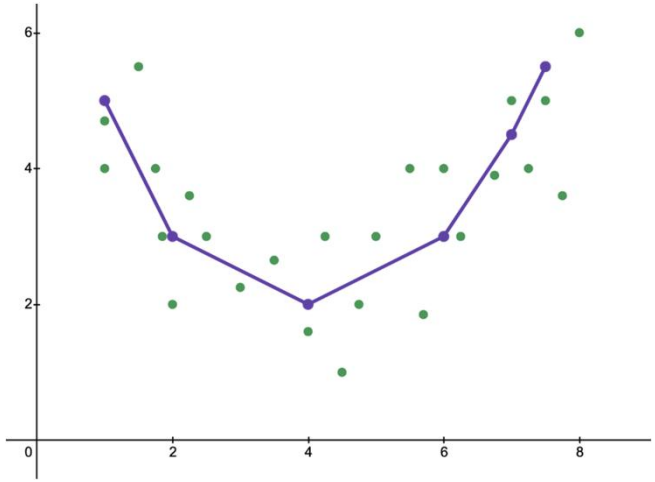

Causas do Sub Ajuste

1. Modelo muito simples
2. Conjunto de dados muito pequeno
3. Seleção inadequada de atributos
4. Falta de ajuste de hiperparâmetros